DOCUMENT DE SPÉCIFICATIONS ET FICHE TECHNIQUE

Projet : Système de Recommandation basé sur Graph Learning avec LightGCN

Étudiante : NGOUMI MAHATANG Lorelle
Matricule : 22P030
Sous la direction de : M. BITHA Junior

---

1. Présentation et Contexte

Résumé du projet

Le présent projet consiste à concevoir, implémenter et évaluer un système de recommandation moderne de bout en bout basé sur l'architecture de Graph Learning **LightGCN (Light Graph Convolution Network)**.

Contrairement aux méthodes classiques de factorisation de matrices, qui reposent uniquement sur des interactions directes utilisateur–item, LightGCN exploite la structure de graphe biparti pour capturer les relations de voisinage d'ordre supérieur. Cela permet de modéliser des influences indirectes entre utilisateurs et films via la propagation d'informations sur plusieurs couches du graphe. Les interactions sont représentées sous forme d'un graphe biparti utilisateur–film, dans lequel les préférences sont propagées afin de générer des recommandations personnalisées de type **Top-K**, tout en améliorant la capacité du modèle à atténuer partiellement le problème du **cold-start**.

Public cible

- **Utilisateurs Finaux :** Utilisateurs d'une plateforme de streaming de films souhaitant recevoir des recommandations personnalisées, pertinentes et ordonnées selon leurs préférences implicites.
- **Équipe Technique :** Ingénieurs en intelligence artificielle, data scientists et développeurs souhaitant étudier, reproduire ou déployer une architecture de filtrage collaboratif basée sur les graphes.

Contraintes et Limites

- **Cold-start :** Une proportion significative de films (~55,4 %) présente peu ou pas d'interactions, ce qui limite la qualité des recommandations pour ces éléments.
- **Sparsité du graphe :** Le graphe utilisateur–film est fortement creux, avec une densité estimée à environ 1,26 %, ce qui impose une modélisation efficace des relations latentes.
- **Jeu de données :** `MovieLens Latest Small (ml-latest-small)`
  - 100 836 interactions
  - 610 utilisateurs

- 9 724 films

2. Périmètre Fonctionnel

Modules et fonctionnalités principales

- **Module de Traitement et Filtrage Implicite** : Charge les données brutes, applique un binarisation stricte (seuil ≥ 4 pour ne retenir que les interactions positives) et convertit les données explicites en signal implicite.
- **Module Graph Builder :** Construit le graphe biparti utilisateurs-films et génère la matrice d'adjacence normalisée symétrique.
- **Générateur de Recommandations Top-k :** Calcule le score d'affinité (produit scalaire) entre un utilisateur et l'ensemble des films non vus pour extraire les k meilleures suggestions.

Cas d'usage et règles métier

- **Scénario Utilisateur :** L'utilisateur se connecte à son profil. Le système analyse l'historique de ses connexions directes et indirectes, puis affiche une liste ordonnée des 20 films les plus susceptibles de lui plaire.
- **Règles métier :**
  - Seules les notes initiales ≥ 4 créent une arête dans le graphe d'entraînement.

3. Spécifications Techniques

Architecture et Exploration des Techniques

L'application suit une architecture pipeline de Deep Learning sur Graphes. Le cœur du système est composé d'une couche d'embeddings initiaux suivie de 3 couches de convolution linéaire sur graphe sans transformation non linéaire ni matrice de poids apprenable.

Pipeline global du système

1. Chargement et prétraitement des données
2. Construction du graphe biparti
3. Propagation LightGCN (forward pass)
4. Extraction des embeddings finaux
5. Calcul des scores de recommandation
6. Génération du Top-K

Technologies utilisées

- **Langage de programmation :** Python
- **Framework Deep Learning:** `PyTorch`
- **Manipulation des données :** `Pandas, Numpy, Scipy...`
- **Déploiement Web :** Micro-framework `Flask` (Python) pour le backend, HTML5 / CSS3 pour le frontend.
- **Visualisation :** `Matplotlib, Seaborn`

Flux de données

Données brutes → Nettoyage → Encodage → Graphe biparti → LightGCN → Embeddings → Scoring → Recommandations Top-K → Interface utilisateur

Évaluation du modèle

Les performances sont mesurées à l'aide de :

- Recall@K : capacité à retrouver les items pertinents
- NDCG@K : qualité du classement des recommandations
- Loss BPR (Bayesian Personalized Ranking) : optimisation des préférences relatives

4. Normes et Exploitation

Sécurité et conformité

- **Régularisation L2 :** Application d'un coefficient de pénalité de poids $\lambda = 10^{-4}$ sur la couche 0 pour empêcher l'espace latent d'exploser et prémunir le modèle contre le surapprentissage.

Déploiement

Le modèle est encapsulé dans une application Flask permettant :

- Sélection dynamique des utilisateurs
- Génération de recommandations en temps réel
- Visualisation des métriques de performance