



ÉCOLE NATIONALE SUPÉRIEURE POLYTECHNIQUE DE YAOUNDÉ (ENSPY) PROJET 1 : Système de Recommandation basé sur LightGCN

ANI-IA 4048: Intelligence Artificielle et Applications

Étudiante : NGOUMI MAHATANG Lorelle (Matricule : 22P030)
Sous la direction de : M. BITHA Junior

1. Phase 1 : Étude théorique

Contrairement aux approches traditionnelles par factorisation de matrice qui souffrent de l'absence de capture des connexions de voisinages d'ordres supérieurs, le modèle **LightGCN** modélise explicitement l'interaction utilisateur-film sous forme d'un graphe biparti.

La simplification majeure de LightGCN par rapport aux architectures GCN classiques réside dans l'abandon des transformations non linéaires et des matrices de poids apprenables lors du processus de *Message Passing*.

Pour guider l'espace vers un classement de préférences (*pairwise ranking*), nous exploitons la fonction de perte **BPR Loss** (*Bayesian Personalized Ranking*), qui force le produit scalaire d'une paire positive à surpasser celui d'une paire négative.

2. Phase 2 : Préparation des données

La transformation des données brutes en structures matricielles creuses hautement optimisées régit la qualité du signal collaboratif. Le jeu de données brut **ml-latest-small** comprend **100 836 interactions** explicites distribuées sur **610 utilisateurs** et **9 724 films**.

2.1. Filtrage Implicite et Densité du Graphe

Conformément à la spécification, les notes explicites ont été binarisées. Le choix d'un seuil ≥ 4.0 permet de ne conserver que les interactions représentatives d'une réelle préférence.

La figure ci-dessous détaille les répercussions de ce traitement :

Analyse Exploratoire des Données — MovieLens Small




FIGURE 1 – Analyse exploratoire

- **Volume et Élagage** : Le diagramme circulaire (en bas à droite) démontre que **51.8 %** des notes sont éliminées (52 256 interactions inférieures à 4.0). Seules **48 580 interactions** positives sont retenues.
- **Densité Critique** : Le filtrage réduit le catalogue de films actifs à 6 298. La densité du graphe post-filtrage se stabilise à un niveau d'extrême parcimonie :

$$\text{Densité} = \frac{48\,580}{609 \times 6\,298} \approx 1.26\%$$

2.2. Le Phénomène de Cold-Start

Le degré moyen des utilisateurs s'élève à 79.8 interactions (médiane à 40). En revanche, le degré des films montre une précarité informationnelle majeure : la moyenne est de 7.7 interactions par film, mais sa médiane se situe à seulement 2 interactions. De ce fait, **55.4 % des films actifs** se trouvent en situation de **Cold-Start** (degré ≤ 2).

3. Phase 3 : Implémentation du modèle LightGCN

L'architecture a été codée de manière modulaire sous PyTorch. La couche initiale d'embeddings (Couche 0) associe à chaque nœud un vecteur de dimension $d = 64$. Le volume total de paramètres entraînaables est déterminé par la taille des tables d'embeddings initiales :

$$\text{Total Paramètres} = (|U| + |I|) \times d = (609 + 6\,298) \times 64 = 442\,048 \text{ paramètres}$$

4. Phase 4 : Entraînement du modèle

L'optimisation des 442 048 paramètres s'est déroulée sur 20 époques complètes à l'aide de l'optimiseur Adam, par mini-lots (*batch size* = 1024). Une régularisation L2 ($\lambda = 10^{-4}$) pénalise la norme des embeddings de la couche 0 pour éviter le surapprentissage.




FIGURE 2 – Fonction de perte BPR

On observe un comportement d'apprentissage optimal :

- **Époques 1 à 4** : La perte BPR subit un effondrement quadratique, chutant de 0.693 à 0.268. Le modèle acquiert rapidement la capacité globale à discriminer les paires d'arêtes valides des arêtes échantillonnées aléatoirement.
- **Époques 5 à 20** : La descente converge vers sa valeur finale de **0.085** à la 20e époque. L'absence d'oscillations ou de remontée de la courbe atteste de la bonne stabilité de l'entraînement.

5. Phase 5 : Évaluation des performances

Toutes les deux époques, le modèle a fait l'objet d'un audit de généralisation, en générant des prédictions de type Top-20. Les profils empiriques du **Recall** et du **NDCG** sont transcrits sur la figure ci-dessous :




FIGURE 3 – Performances de recommandation

Époque	BPR Loss	Recall@20	NDCG@20
1	0.6929	16.58%	16.08%
2	0.6176	15.76%	15.62%
4	0.2679	20.04%	18.56%
6	0.1898	20.91%	19.53%
10	0.1420	21.58%	20.12%
16	0.1025	22.04%	20.94%
20	0.0853	22.49%	21.44%

TABLE 1 – Métriques de performance de recommandation au cours des époques

5.1. Analyse fine du Recall@20

À l'époque 20, le Recall@20 atteint **22.49 %**. Cela démontre que pour chaque utilisateur, le réseau extrait près d'un quart de ses préférences futures réelles au sein d'un échantillon d'affichage très restreint (20 suggestions sur 6 298 films disponibles).

5.2. Analyse fine du NDCG@20

La marge séparant le Recall@20 du NDCG@20 ($\approx 1.05\%$) constitue l'indicateur de performance le plus probant : elle certifie mathématiquement que les films pertinents trouvés ne sont pas simplement présents dans le Top-20, mais sont majoritairement ordonnés au sommet de la liste de recommandation.

6. Phase 6 : Analyse et interprétation

6.1. Analyse de la Matrice de Similarité Cosinus

La carte de gauche de la figure ci dessous évalue la similarité cosinus croisée des 20 premiers utilisateurs du dataset :

- **Structuration Communautaire** : On observe l'apparition de blocs de forte intensité verte (similarité ≥ 0.50). Des utilisateurs partageant des affinités similaires voient leurs embeddings converger vers des régions connexes de l'espace latent.
- **Marginalisation des profils atypiques** : On remarque l'empreinte de l'Utilisateur 2, qui génère une bande verticale de faible corrélation, traduisant un profil cinématographique singulier ou un faible volume d'arêtes d'entraînement l'isolant du reste de la population.

6.2. Analyse de la Distribution des Normes

L'histogramme de droite formalise l'impact structurel du **Message Passing** linéaire :

- **Embeddings des Films (Orange)** : Ils présentent une distribution extrêmement resserrée et stable autour de la valeur (1.0).
- **Embeddings des Utilisateurs (Bleu)** : On observe un étalement massif des normes L2, s'étendant de 2 jusqu'à près de 6. Plus un utilisateur a vu et aimé de films, plus son vecteur s'allonge et s'éloigne de zéro parce qu'il accumule les caractéristiques de tous ces films à chaque étape du calcul.




FIGURE 4 – Analyse des embeddings

Conclusion

En conclusion, ce projet démontre la grande efficacité du modèle LightGCN pour la recommandation de films. Malgré un fort taux de films très peu notés au départ, la propagation des informations à travers le graphe a permis de comprendre précisément les affinités des utilisateurs. Les scores obtenus, tant pour trouver les bons films (**Recall@20 = 22,49 %**) que pour les placer au début de la liste (**NDCG@20 = 21,44 %**), confirment que ce système est à la fois fiable, performant.